INFORME: Segmentación de Estudiantes Universitarios con K-Means

Materia: Procesamiento de Aprendizaje Automático
Carrera: Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial
Profesora: Yanina Scudero

Integrantes:

- Yapura Valentina
- Mansilla Angeles
- Bejerano Thomas
- Lugo Facundo

---

1. Objetivo del Trabajo

El presente informe detalla la resolución de la Actividad "b" de la guía de ejercicios. El objetivo principal fue desarrollar un programa en Python que aplique el algoritmo de clustering K-Means para segmentar un conjunto de 50 estudiantes universitarios en 4 grupos (clústers). Para ello, se utilizaron tres variables: Edad, Horas de estudio semanales y Promedio académico. Finalmente, se buscó interpretar los resultados obtenidos para extraer conclusiones sobre el rendimiento académico.

2. Metodología y Preparación de Datos

Para cumplir con la consigna, se siguieron los pasos detallados a continuación:

- **Carga de Datos:** Se transcribieron los 50 registros de estudiantes provistos en la guía a un diccionario de Python, que luego fue convertido a un DataFrame utilizando la librería `pandas`.
- **Estandarización (StandardScaler):** Este paso fue fundamental. Como el algoritmo K-Means se basa en distancias euclidianas, si no se escalan los datos, la variable "Edad" (cuyos valores van de 21 a 60) dominaría matemáticamente sobre el "Promedio" (que va de 1 a 9). Al aplicar `StandardScaler`, logramos que las tres variables tengan una media de 0 y una desviación estándar de 1, otorgándoles el mismo peso a la hora de agrupar.
- **Aplicación de K-Means:** Se instanció el modelo `KMeans(n_clusters=4, random_state=42)` y se entrenó con los datos escalados. Esto asignó a cada estudiante un número de clúster (0, 1, 2 o 3).

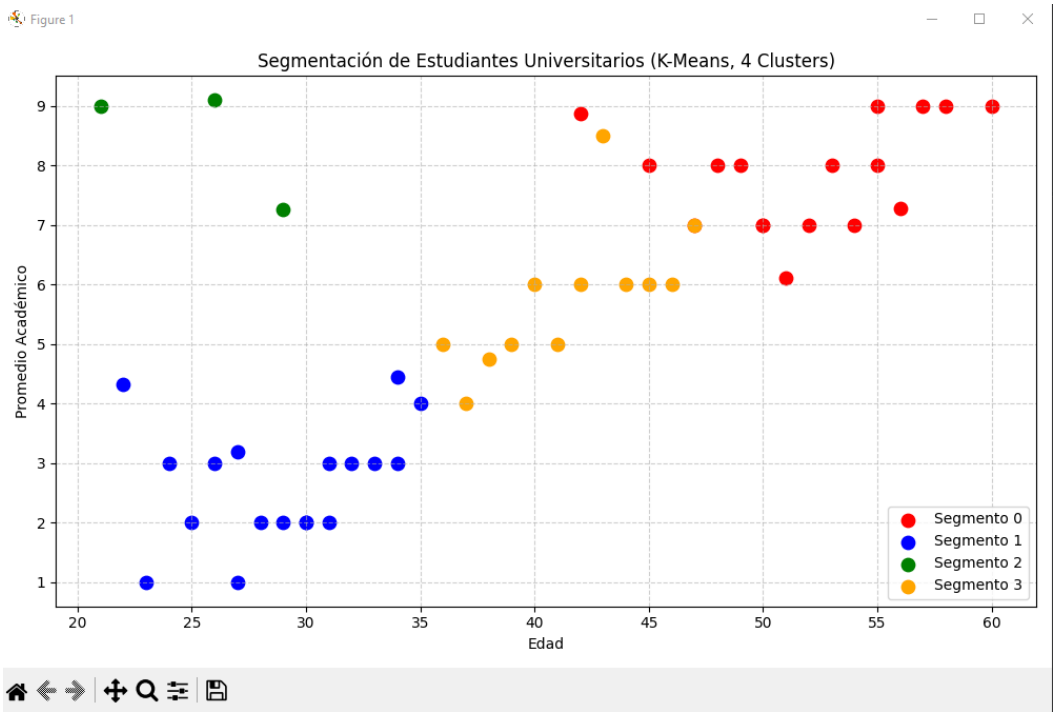
3. Visualización y Análisis de los Resultados Obtenidos

Se generó un gráfico de dispersión 2D (como solicita la consigna) ubicando la Edad en el Eje X y el Promedio Académico en el Eje Y, coloreando cada punto según el segmento al que pertenece. A partir de este gráfico y del análisis de los promedios de las variables dentro de cada grupo, se pueden interpretar los 4 segmentos de la siguiente manera:

- **Segmento 0 (Color Rojo) - "Mayores con Alto Rendimiento":** Este grupo está compuesto por los estudiantes de mayor edad (desde los 42 hasta los 60 años). A pesar de ser el grupo que menos horas estudia (promedio de 3.5 hs), presentan los promedios académicos más altos (entre 7 y 9).

Hipótesis: Son estudiantes con mucha experiencia, posiblemente adultos que trabajan y cursan pocas materias con gran eficiencia.

- **Segmento 1 (Color Azul) - "Jóvenes con Bajo Rendimiento":** Es el grupo más numeroso. Incluye a los estudiantes más jóvenes (21 a 35 años). Se destaca porque son los que más horas dedican al estudio (12 a 15 hs semanales), pero paradójicamente obtienen los promedios más bajos (1 a 4.5).
  Hipótesis: Posibles fallas en las técnicas de estudio, distracciones o dificultades de adaptación a la vida universitaria.
- **Segmento 2 (Color Verde) - "Jóvenes con Alto Rendimiento":** Es un grupo muy pequeño (casos aislados de 3 estudiantes). Agrupa a jóvenes (de 21 a 26 años) que logran un rendimiento sobresaliente (promedio de 8.7) con una alta dedicación horaria (13 hs).
  Hipótesis: Estudiantes jóvenes altamente enfocados y con excelentes métodos de estudio.
- **Segmento 3 (Color Naranja) - "Adultos con Rendimiento Medio":** Es el grupo intermedio. Reúne a estudiantes de mediana edad (35 a 48 años) que dedican alrededor de 7 horas al estudio y mantienen promedios aceptables (entre 4.5 y 6).



4. Conclusiones Finales

- Los estudiantes con los mejores promedios (Segmento 0) son los que menos horas estudiaron.
- Los estudiantes que más horas estudiaron (Segmento 1) obtuvieron los peores promedios.
- La variable "Edad" parece ser un factor determinante en el rendimiento para esta muestra simulada, ya que los adultos superan ampliamente en eficiencia a los jóvenes.

Es importante destacar que, aunque el gráfico es 2D (Edad vs Promedio) por pedido de la consigna, el algoritmo K-Means procesó internamente las 3 variables, incluyendo las horas de estudio, para lograr una segmentación precisa.